

다국어 입력 환경에서 동일 **LLM** 패밀리의

추론 안정성과 오류 유형 비교 분석

P2-Bench: Claude Opus 5.5 와 **Claude Sonnet 5.5** 를 중심으로

Reasoning Stability and Error Patterns Across Languages Within an LLM Family:

A P2-Bench Study of Claude Opus 5.5 and Claude Sonnet 5.5

최종 제출본 | 2026-10-06

초록

본 연구는 동일 대규모 언어 모델 (LLM) 패밀리 내에서 모델 등급과 입력 언어가 추론 안정성, 오류 유형, 설명 품질에 미치는 영향을 비교하기 위해 P2-Bench 를 설계하고 Claude Opus 5.5 와 Claude Sonnet 5.5 를 평가하였다. P2-Bench 는 Mathematics, Logic, Science, Error Detection 의 네 영역에서 60 개 한국어·영어 대응 문항을 제공하며, 최종 답 정확성(40), 추론 과정(25), 조건 검토(15), 오류 인정·검증(10), 설명 명확성(10)의 100 점 루브릭과 오류코드를 결합한다. 최종 본실험은 2 개 모델 × 2 개 언어 × 60 문항의 240 개 응답으로 구성되었다. R2 QC 이후 236 개 응답(98.3%)이 100 점을 기록했으며, Opus 는 KR/EN 모두 평균 100.000, Sonnet 은 KR 100.000, EN 99.817 이었다. Sonnet KR-EN 및 Opus-Sonnet EN 비교에서 평균 paired difference 는 각각 0.183 점이었고 exact sign test 는 $p=0.125$, Cohen's d_z 는 약 0.245 였다. 비완벽 응답 4 건은 모두 Sonnet-EN 에서 관찰되었으나, 강한 ceiling effect 때문에 안정적인 모델 또는 언어 효과로 일반화하기에는 근거가 제한적이었다. 질적 오류 분석에서는 일시적 논리 오류와 조건 해석 오류의 자기수정, 정보불충분 상황에서의 과잉추론, 설명 내부의 국소적 모순이 관찰되었다. 결과는 최신 고성능 LLM 에서 단순 평균 점수보다 언어 간 paired stability 와 실패·회복 패턴, 그리고 벤치마크 자체의 변별력을 함께 분석할 필요가 있음을 보여준다.

주요어: 대규모 언어 모델, 다국어 추론, 교차언어 평가, 추론 안정성, 오류 분석, Claude, 벤치마크

English Abstract

This study introduces P2-Bench to examine how model tier and input language affect reasoning stability, error patterns, and explanation quality within a single large language model family. Claude Opus 5.5 and Claude Sonnet 5.5 were evaluated on 60 paired Korean and English items spanning Mathematics, Logic, Science, and Error Detection, yielding 240 main-experiment responses. Responses were scored on a 100-point rubric covering final-answer accuracy, reasoning quality, condition checking, error recognition and verification, and explanation clarity. After R2 quality control, 236 of 240 responses (98.3%) received perfect scores, revealing a pronounced ceiling effect. Opus achieved 100.000 in both Korean and English, while Sonnet achieved 100.000 in Korean and 99.817 in English. For Sonnet, the mean paired difference between Korean and English was 0.183 points; four non-zero differences all favored Korean, but the exact sign test was not statistically significant ($p = .125$; Cohen's $d_z = 0.245$). All four non-perfect responses occurred under the Sonnet-English condition and included transient logical and condition-interpretation errors followed by self-correction, over-inference under insufficient information, and a localized inconsistency in explanation. The findings therefore do not support a strong ranking claim between the two models. Instead, they show that, under a saturated benchmark, qualitative failure and recovery patterns can be more informative than mean-score differences. The 98.3% ceiling rate also provides empirical

evidence that future versions of P2-Bench should increase item difficulty and strengthen fine-grained evaluation of transient errors, self-correction, and uncertainty calibration.

Keywords: large language model, multilingual reasoning, cross-lingual evaluation, reasoning stability, error analysis, Claude, benchmark

1. Introduction

대규모 언어 모델의 성능 평가가 영어 중심의 단일 점수 비교에서 실제 사용 환경의 안정성 평가로 확장되면서, 동일한 의미의 문제가 언어만 달라졌을 때 모델의 추론 결과가 얼마나 일관되게 유지되는지가 중요한 연구 문제로 부상하고 있다. 다국어 추론 연구는 수학 문제를 중심으로 모델 규모가 커질수록 여러 언어에서 chain-of-thought 추론이 가능해짐을 보였지만(Shi et al., 2023), 후속 연구는 언어별 성능 편차와 다국어 추론 일관성이 여전히 완전히 해결되지 않았음을 보고하였다(Lai & Nissim, 2024).

본 연구의 관심은 단순한 모델 순위가 아니다. 동일 모델 패밀리 안에서도 상위 등급과 범용 등급이 입력 언어 변화에 대해 동일한 안정성을 보이는지, 그리고 실패가 발생할 때 그 실패가 계산, 조건 해석, 정보 충분성, 논리적 추론, 자기수정과 같은 어떤 형태로 나타나는지를 분석하는 데 목적이 있다. 이러한 관점은 단일 정답률이나 평균 점수가 포착하지 못하는 추론의 질적 차이를 드러낼 수 있다.

이에 본 연구는 P2-Bench를 이용하여 Claude 5.5 패밀리의 Opus 5.5와 Sonnet 5.5를 한국어와 영어 조건에서 동일한 60 문항으로 평가한다. Anthropic은 Opus 5.5를 복잡한 작업과 높은 판단 요구를 위한 상위 모델로, Sonnet 5.5를 더 빠르고 비용 효율적인 보완 모델로 설명하고 있다(Anthropic, 2026a; 2026b). 동일 공급자 및 동일 세대의 두 모델을 비교함으로써 공급자 간 시스템 차이보다 모델 등급과 입력 언어의 관계에 초점을 맞춘다.

1.1 Research Gap and Contributions

기존 다국어 추론 연구는 MGSM과 mCoT-MATH처럼 수학 중심 과제에서 언어별 정확도 또는 추론 일관성을 측정하는 경우가 많았고, SeaEval은 이를 의미적 일관성과 문화적 추론으로 확장하였다. 최근에는 multilingual chain-of-thought의 성능뿐 아니라 reasoning trace의 언어별 일관성과 faithfulness를 직접 측정하려는 연구도 등장했다(Zhao et al., 2025). 그러나 동일 상용 모델 패밀리의 서로 다른 등급을 대상으로, 한국어와 영어의 동일 문항을 paired structure로 고정하고, 최종 정답뿐 아니라 조건 검토·오류 인식·자기수정·설명 품질을 함께 정량화한 연구는 상대적으로 제한적이다.

본 연구의 기여는 세 가지다. 첫째, 동일 Question_ID의 KR/EN 쌍을 사용해 언어 변화에 따른 추론 안정성을 직접 비교한다. 둘째, 동일 공급자의 Opus와 Sonnet을 비교하여 공급자·플랫폼 차이에서 발생할 수 있는 교란을 줄이고 모델 등급 효과를 탐색한다. 셋째, 최종 정답 정확도에 더해 transient error, self-correction, information-sufficiency failure, over-inference를 기록함으로써 고성능 모델에서 평균 점수가 포착하지 못하는 희소 실패 패턴을 분석한다.

1.2 Research Questions

- RQ1. Claude Opus 5.5 와 Claude Sonnet 5.5 는 동일 문항에서 추론 성능 및 오류 유형에 차이를 보이는가?
- RQ2. 동일 Claude 모델에서 한국어와 영어 입력 조건에 따라 추론 성능, 조건 검토, 설명 품질 및 오류 유형이 달라지는가?
- RQ3. 입력 언어의 효과는 Opus 와 Sonnet 에서 동일한가, 즉 Model × Language 상호작용을 시사하는 패턴이 존재하는가?
- RQ4. 모델 및 언어 효과는 Mathematics, Logic, Science, Error Detection 영역에 따라 다른 양상을 보이는가?

2. Related Work

2.1 Multilingual Reasoning Evaluation

MGSM 은 GSM8K 수학 문항을 10 개 언어로 수동 번역하여 다국어 수학 추론을 평가했으며, 모델 규모가 증가할수록 여러 언어에서 chain-of-thought 추론 능력이 나타남을 보고하였다(Shi et al., 2023). 이 연구는 다국어 추론 평가의 대표적인 출발점이지만, 평가 영역이 수학 중심이라는 한계가 있다.

Lai 와 Nissim(2024)은 mCoT-MATH 를 통해 11개 언어에서 추론 일관성을 분석하고, 기존 LLM 에서 언어별 성능 변동이 상당함을 보고하였다. SeaEval 은 단순 정확도 이외에도 다국어성과 의미 변형에 대한 brittleness 를 평가하며, 의미적으로 동등한 다국어 질의에서 일관된 응답이 기대되어야 함을 강조한다(Wang et al., 2024). 이러한 연구들은 언어 간 평균 정확도뿐 아니라 동일 의미 입력에 대한 안정성 자체가 평가 대상이어야 함을 뒷받침한다.

이 후 Zhao et al.(2025) 은 multilingual chain-of-thought 를 성능 (performance), 일관성 (consistency), 충실성 (faithfulness)의 세 차원으로 확장해 분석하고, prompt language 에 따라 reasoning trace 의 품질과 효과가 달라질 수 있음을 보고하였다. 이는 입력 언어 효과를 단순한 최종 정답률 차이로 환원하기 어렵다는 점을 보여주며, P2-Bench 가 추론 과정과 자기수정을 별도로 기록하는 근거가 된다.

2.2 Translation and Benchmark Validity

다국어 벤치마크에서는 번역 자체가 측정오차의 원인이 될 수 있다. Plaza et al.(2024)은 MMLU 의 스페인어 번역 사례에서 일부 실패가 모델의 언어 능력보다 번역 오류에 기인할 수 있음을 보였다. 따라서 P2-Bench 는 KR/EN 문항을 고정된 쌍으로 관리하고 동일 Question_ID 를 기준으로 paired comparison 을 수행하여 문항별 차이를 직접 추적한다.

2.3 Within-Family Model Comparison

공급자가 서로 다른 모델을 비교할 경우 시스템 프롬프트, 제품 인터페이스, 후처리, 개인화와 같은 요소가 모델 자체의 차이와 혼재될 수 있다. 본 연구는 이러한 교란을 줄이기 위해 동일 Claude 5.5 패밀리 내의 Opus 와 Sonnet 에 분석 범위를 제한하였다. Anthropic 의 공식 설명에서도 Sonnet 5.5 는 Opus 5.5 의 더 빠르고 저비용인 보완 모델로 제시되며, Opus 는 더 복잡한 판단 과제에 초점을 둔다(Anthropic, 2026a; 2026b).

2.4 Benchmark Saturation and Discriminative Evaluation

LLM 성능이 빠르게 향상되면서 기존 벤치마크의 점수가 포화되어 모델 간 차이를 구분하기 어려운 문제도 커지고 있다. MMLU-Pro 는 기존 MMLU 성능이 plateau 에 접근해 변별력이 낮아진다는 문제의식에서 더 복잡한 추론 문항과 확장된 선택지를 도입했고, 기존 MMLU 보다 모델 정확도를 크게 낮추면서 prompt 변화에 대한 안정성도 높였다고 보고하였다(Wang et al., 2024b). LiveBench 역시 더 어려운 최신 문항과 객관적 채점을 통해 개선되는 모델을 계속 구분할 수 있도록 설계되었다(White et al., 2024). GPQA 는 대학원 수준의 전문가 작성 문제를 사용해 당시 강력한 모델에도 어려운 평가 환경을 구축하였다(Rein et al., 2023). 이러한 흐름은 벤치마크의 ceiling effect 자체가 단순한 분석 장애가 아니라 차기 벤치마크 설계의 난이도와 변별력을 재조정해야 한다는 경험적 신호임을 시사한다.

3. Methodology

3.1 Study Design

최종 본실험은 2 개 모델(Claude Opus 5.5, Claude Sonnet 5.5) × 2 개 입력 언어(KR, EN) × 60 개 문항의 완전 교차 설계로 구성되었다(N=240). 동일 모델의 KR/EN 응답은 동일 Question_ID 를 기준으로 paired structure 를 유지하며, 동일 언어에서 Opus 와 Sonnet 또한 같은 문항 단위로 대응된다. 초기에는 GPT 계열을 포함한 3 개 모델 설계를 고려했으나, 플랫폼 개인화와 출력 언어 통제 문제로 인한 잠재적 교란을 줄이기 위해 최종 confirmatory analysis 는 Claude 패밀리로 제한하였다. GPT 관련 행은 삭제하지 않고 분석 제외 아카이브로 보존하였다.

3.2 Benchmark Composition

표 1. P2-Bench v1.0 의 영역별 문항 구성

영역	문항 수	주요 평가 초점
Mathematics	15	계산, 대수, 수열, 비율, 조건 적용
Logic	15	연역 타당성, 조건 논리, 가능세계, 정보 충분성
Science	15	과학적 추론, 실험 설계, 단위·수치 해석, 인과 추론
Error Detection	15	모순·계산오류·근거부족·과잉추론 탐지

영역	문항 수	주요 평가 초점
합계	60	KR/EN 대응 문항

각 문항에는 ID, Category, Difficulty, Question_KR, Question_EN, Correct Answer, Explanation, Evaluation Target, Expected Error Type 이 포함되어 있으며, P2-Bench_Master_Dataset_v1.0 을 단일 기준으로 사용하였다.

3.3 Scoring Rubric

표 2. P2-Bench 100 점 평가 루브릭

평가 항목	배점	평가 내용
최종 답 정확성	40	최종 결론 및 정답의 정확성
추론 과정	25	논리·계산·인과 과정의 타당성과 충분성
조건 검토	15	문제 조건, 정보 충분성, 제약의 적절한 확인
오류 인정·검증	10	검산, 불확실성 인정, 자기수정의 적절성
설명 명확성	10	설명의 구조, 명료성, 불필요한 모순 여부
합계	100	응답당 총점

오류 유형은 NONE, HALL, PREM, LOG, CALC, COND, OVER, UNC, SELF 를 기본 코드로 사용하였다. R1 채점 후 고정 seed 20261002 로 모델×언어×영역별 총화표본을 추출하고, 기존 감점 사례 및 정보불충분 문항을 추가한 intra-rater R2 audit 을 실시하였다. 중복 제거 후 38 개 Run 을 재검토 했으며 1개 Run 의 점수를 추가 조정하였다. 이는 독립된 두 번째 평가자에 의한 inter-rater reliability 검증은 아니다.

3.4 Statistical Analysis

분석은 기술통계, 동일 문항 paired difference, exact sign test, Cohen's d_z , 오류 유형 분석으로 구성하였다. 점수가 상한에 집중될 가능성을 고려하여 평균과 p-value 만으로 결론을 내리지 않고, 비영 차이의 개수와 방향, 오류 사례의 질적 특성, 영역별 분포를 함께 해석하였다.

4. Dataset

P2-Bench 의 최종 기준 데이터셋은 60 문항으로 구성된다. 본 연구에서 1차 예비실험 54 개 응답은 탐색적 설계 근거로만 유지했고 본실험 통계에는 포함하지 않았다. P2V2-R01~R07 로 구성된 2차 예비실험은 중간 중단된 실험으로 모든 분석에서 완전히 제외하였다. 본실험의 모든 결과는 Claude-only 240 개 응답에 기반한다.

5. Experiment

각 응답은 사전에 정의된 `Full_Input_Text` 를 사용하여 수집되었고 원 응답은 수정하지 않고 `Raw_Response` 로 보존하였다. 본실험은 한국어 및 영어 입력의 동일 문항 쌍을 기준으로 구성되었다. 다만 원 관리 파일의 `Exact_Model_Version` 과 `Execution_Date` 필드는 미기록 상태이며, 본 연구는 이를 사후 추정하지 않았다. 따라서 본문에서 사용하는 “Claude Opus 5.5”와 “Claude Sonnet 5.5”는 실험 관리 당시 기록된 모델 그룹 명칭이며, API snapshot 수준의 재현성까지 보장하는 식별자는 아니다. 이 제한은 결과 해석과 재현성 논의에 명시적으로 반영하였다.

6. Results

6.1 Overall Performance and Ceiling Effect

R2 QC 이후 전체 240 개 응답 중 236 개가 100 점을 기록하여 전체 만점 비율은 98.3%였다. 최저 점수는 96 점이었다. Opus 는 120 개 응답 전체가 100 점이었고, Sonnet 은 120 개 중 116 개 (96.7%)가 100 점이었다. 언어별로는 KR 120 개 전체가 100 점이었고, EN 은 120 개 중 116 개가 100 점이었다. 이는 본 벤치마크와 평가 루브릭에서 매우 강한 ceiling effect 가 발생했음을 의미한다.

표 3. 모델-언어 조건별 기술통계

조건	N	평균	중앙값	표준편차	만점 비율
Opus-KR	60	100.000	100	0.000	100.0%
Opus-EN	60	100.000	100	0.000	100.0%
Sonnet-KR	60	100.000	100	0.000	100.0%
Sonnet-EN	60	99.817	100	0.748	93.3%
전체	240	99.954	100	0.389	98.3%




그림 1. P2-Bench 총점 분포와 ceiling effect

주. R2 QC 기준. 240 개 응답 중 236 개(98.3%)가 100 점을 기록하였다.

6.2 Paired Language Comparison

Opus에서는 60 개 문항 모두 KR 과 EN 점수가 동일하여 paired difference 가 전부 0 이었다. Sonnet에서는 KR 평균이 100.000, EN 평균이 99.817 로 평균 차이(KR-EN)는 0.183 점이었다. 60 개 문항 중 비영 차이는 4 개였으며 모두 KR 점수가 EN 보다 높았다. exact sign test 는 $p=0.125$ 였고 Cohen's d_z 는 약 0.245 였다. 따라서 관찰된 방향성은 존재하지만 통계적 유의성을 주장할 근거는 충분하지 않다.

6.3 Paired Model Comparison

한국어 조건에서는 Opus 와 Sonnet 의 60 개 문항 점수가 모두 동일했다. 영어 조건에서는 Opus 평균 100.000, Sonnet 평균 99.817 로 평균 차이(Opus-Sonnet)는 0.183 점이었다. 비영 차이는 4 개 였고 모두 Opus 우세 방향이었다. exact sign test $p=0.125$, Cohen's $d_z \approx 0.245$ 로 Sonnet 의 언어 비교와 동일한 수치를 보였다. 이는 감점된 네 사례가 모두 Sonnet-EN 조건에 집중되었기 때문이다.

표 4. 동일 문항 기반 paired 비교 결과

비교	Pair N	평균차	비영 차이	방향	Exact sign p	Cohen d_z
Opus KR vs EN	60	0.000	0	없음	-	0.000

비교	Pair N	평균차	비영 차이	방향	Exact sign p	Cohen d_z
Sonnet KR vs EN	60	0.183	4	KR > EN 4	0.125	0.245
Opus vs Sonnet KR	60	0.000	0	없음	-	0.000
Opus vs Sonnet EN	60	0.183	4	Opus > Sonnet 4	0.125	0.245

6.4 Category-Level Results

영역별 차이 역시 Sonnet-EN에서만 나타났다. Mathematics는 15 문항 전부 100 점으로 차이가 없었다. Logic 과 Science에서는 각각 1개 문항이 감점되어 평균 99.8 점, Error Detection에서는 2개 문항이 감점되어 평균 99.667 점이었다. 그러나 각 영역의 비영 차이가 0~2 개에 불과하므로 영역 효과를 안정적으로 일반화하기 어렵다.

표 5. 영역별 평균 점수

영역	Opus-KR	Opus-EN	Sonnet-KR	Sonnet-EN
Mathematics	100.000	100.000	100.000	100.000
Logic	100.000	100.000	100.000	99.800
Science	100.000	100.000	100.000	99.800
Error Detection	100.000	100.000	100.000	99.667




그림 2. 비완벽 응답의 영역별 분포

주. 비완벽 응답 4 건은 모두 Claude Sonnet 5.5 의 영어 입력 조건에서 발생하였다.

7. Error Analysis

비완벽 응답은 총 4 건으로 전체의 1.7%였다. 네 사례 모두 Claude Sonnet 5.5 의 영어 입력 조건에서 발생했다. 환각(HALL)으로 분류된 사례는 없었으며, 두 사례에서는 초기 오류를 모델이 응답 내에서 스스로 수정하였다.

표 6. 비완벽 응답 4 건의 오류 특성

Run_ID	영역/문항	점수	오류	자기수정	핵심 관찰
P2M-02-052	Logic / L15	97	LOG	Yes	초기에 단일 범인을 단정했으나 경우분석 후 "유일 결정 불가"로 철회
P2M-02-100	Science / S05	97	COND	Yes	첫 문장에서 제한 반응물을 잘못 적었으나 몰비 계산으로 즉시 수정
P2M-02-104	Error Detection / E15	96	OVER + UNC	N/A	출생연도 결정 불가를 맞게 판정한 뒤 근거 없는 출생 시기 추정을 추가
P2M-02-109	Error Detection / E01	99	NONE	N/A	핵심 계산 오류 탐지는 정확하나 설명 문장 일부가 후속 설명과 국소적으로 모순

7.1 Self-Correction as a Distinctive Failure-Recovery Pattern

L15 와 S05 는 최종 정답만 평가할 경우 완전한 성공으로 간주될 수 있으나, 전체 응답을 보면 초기 추론 단계에서 오류가 발생한 뒤 모델이 이를 바로잡았다. 이는 최종 정확도와 추론 안정성이 동일한 개념이 아님을 보여준다. 특히 고성능 모델 평가에서 최종 답만으로는 transient error 를 포착하기 어렵기 때문에 자기수정 여부를 별도 변수로 기록하는 것이 유용하다.

7.2 Information Sufficiency and Over-Inference

E15 사례는 정보가 부족하다는 핵심 판단 자체는 정확했지만, 그 이후 자료가 지지하지 않는 구체적 시기를 추정했다. Error Detection 과제에서는 "틀린 추론을 알아차리는 능력"뿐 아니라 불필요한 추가 추론을 억제하는 능력이 중요하다. 따라서 정보 충분성 실패(UNC)와 과잉일반화 또는 과잉추론(OVER)을 분리해 기록할 필요가 있다.

8. Discussion

8.1 Interpretation of RQ1-RQ4

RQ1과 관련하여 Opus와 Sonnet 사이에 큰 성능 격차는 관찰되지 않았다. 한국어 조건에서는 두 모델이 완전히 동일한 점수를 보였고, 영어 조건에서도 평균차는 0.183 점에 불과했다. 따라서 본 데이터는 “Opus가 전반적으로 Sonnet보다 우수하다”는 강한 서열 결론을 지지하지 않는다.

RQ2에서는 Opus의 KR/EN 차이가 전혀 없었고 Sonnet에서만 네 개의 비영 paired difference가 관찰되었다. 모든 차이가 KR 우세 방향이라는 점은 주목할 수 있지만, 비영 관측치가 매우 적고 $p=0.125$ 이므로 언어 효과의 존재를 통계적으로 확정할 수 없다.

RQ3의 Model $\times$ Language 관점에서는 비완벽 응답이 모두 Sonnet-EN에 집중되었다는 패턴이 존재한다. 그러나 이 패턴은 네 사례에 의해 형성되므로 안정적인 상호작용 효과로 일반화하기보다는 후속 실험에서 검증할 탐색적 신호로 해석하는 것이 타당하다.

RQ4에서는 Error Detection에서 가장 많은 비완벽 사례가 발생했고 Logic과 Science에서 각각 한 사례가 발생했다. Mathematics에서는 차이가 없었다. 하지만 하위영역별 사례 수가 매우 적어 영역별 난이도 차이나 취약성을 확정하기 어렵다.

8.2 Ceiling Effect as an Empirical Finding

본 연구에서는 98.3%의 응답이 만점을 기록했다. 이는 단순히 “실험 실패”로 처리하기보다 현재 수준의 상용 고성능 LLM에 대해 P2-Bench v1.0의 문항 난이도와 100점 루브릭이 충분한 변별력을 제공하지 못했다는 경험적 결과로 해석할 수 있다. 즉 P2-Bench v1.0은 명백한 오류 탐지와 기본적인 추론 능력을 확인하는 데는 유효하지만, 매우 높은 성능의 최신 모델 사이 미세한 차이를 안정적으로 구분하는 데에는 한계가 있다.

이 ceiling effect는 다국어 추론 평가에서 평균 점수만 사용하는 접근의 한계를 강화한다. 점수 차이가 거의 사라질 때는 transient error, 자기수정, 과잉추론, 설명 내부 모순과 같은 질적 패턴이 더 높은 정보 가치를 가질 수 있다. 따라서 후속 P2-Bench v2에서는 adversarial distractor, underspecified premise, multi-step constraint interaction, calibrated uncertainty와 같은 문항을 확대할 필요가 있다.

8.3 Relation to Prior Multilingual Evaluation

선행 연구는 모델이 여러 언어에서 강한 추론 능력을 보이면서도 언어별 일관성에는 변동이 존재할 수 있음을 보여왔다(Shi et al., 2023; Lai & Nissim, 2024). SeaEval 역시 의미적으로 등가인 다국어 입력에서 일관성이 중요한 평가 차원임을 강조한다(Wang et al., 2024). 본 연구의 결과는 이러한 문제의식을 최신 상용 동일 패밀리 모델에 적용했다는 점에서 의미가 있다. 다만 본 데이터에서는 언어 간 차이가 대규모 성능 차이보다는 소수의 오류 회복·과잉추론 사례로 나타났다.

8.4 Implications for Benchmark Design

P2-Bench v1.0 의 98.3% 만점률은 현재 문항 집합이 기본적인 수학·논리·과학·오류 탐지 능력을 확인하는 데는 충분하지만, 최신 상용 고성능 모델의 미세한 차이를 분리하기에는 난도가 낮다는 점을 보여준다. 이는 MMLU-Pro, LiveBench, GPQA 가 더 어려운 문항과 오염·채점 문제를 고려해 변별력을 높이려 한 최근 평가 흐름과 일치한다. 따라서 P2-Bench v2 에서는 단순히 문항 수를 늘리기보다, 조건 간 미세 충돌, 정보 불충분, 유혹적인 오답 근거, 다단계 제약, 장거리 의존, 설명-정답 불일치와 같이 reasoning process 를 교란하는 문항을 체계적으로 추가할 필요가 있다.

또한 ceiling 상황에서는 연속 점수의 평균 차이보다 문항별 discordance 와 오류 전이(error transition)가 더 직접적인 정보를 제공할 수 있다. 예컨대 동일 문항의 KR/EN 에서 최종 답은 같더라도 한 조건에서만 초기 오류 후 자기수정이 나타나는 경우, 이를 "동일 성능"으로 처리하면 추론 안정성 차이가 소실된다. 후속 버전에서는 최종답, 중간 추론 오류, 자기수정, 정보충분성 판단을 분리한 다층 평가를 강화하는 것이 바람직하다.

9. Limitations

첫째, 본 연구는 단일 공급자의 Claude 5.5 패밀리에 국한되므로 결과를 LLM 일반에 직접 일반화할 수 없다. 둘째, 문항 수는 60 개이며 영역별 15 개로 제한되어 있다. 셋째, 전체 응답의 98.3%가 만점이어서 통계적 검정력이 낮고 평균 차이 기반 분석의 해석 범위가 제한된다. 넷째, R2 QC 는 동일 평가자의 intra-rater audit 이며 독립 평가자 간 신뢰도(inter-rater reliability)를 측정하지 않았다. 다섯째, Exact_Model_Version 과 Execution_Date 가 미기록이어서 세부 모델 snapshot 과 실행 시점을 완전히 재현할 수 없다. 여섯째, KR/EN 대응 문항은 paired comparison 을 위해 고정되었지만, 번역·표현 차이가 난이도에 미치는 영향을 별도의 인간 번역 품질 평정으로 검증하지 않았다. Plaza et al. (2024)이 지적하듯 다국어 벤치마크에서는 번역 품질이 모델 성능과 혼재될 수 있다. 일곱째, 비공개 상용 모델의 학습 데이터에 P2-Bench 와 유사한 문항 또는 일반적 문제 유형이 포함되었는지 확인할 수 없으므로 데이터 오염 가능성을 완전히 배제할 수 없다.

10. Conclusion

P2-Bench 를 이용해 Claude Opus 5.5 와 Claude Sonnet 5.5 의 한국어·영어 추론을 비교한 결과, 두 모델 모두 매우 높은 성능을 보였으며 전체의 98.3%가 만점이었다. Opus 에서는 언어 간 차이가 관찰되지 않았고, Sonnet 에서는 영어 조건의 네 문항에서만 소폭 감점이 발생했다. paired 분석에서 Sonnet KR-EN 및 Opus-Sonnet EN 의 평균차는 0.183 점, exact sign test $p=0.125$, $d_z \approx 0.245$ 로 나타났으나 ceiling effect 와 비영 차이의 희소성 때문에 강한 모델 또는 언어 효과를 주장하기 어렵다.

본 연구의 핵심 기여는 최신 고성능 모델에서 평균 성능 차이보다 실패의 형태와 회복 패턴을 분석하는 것이 중요하다는 점을 보여준 데 있다. 자기수정이 가능한 transient logical/condition errors,

정보불충분 상황에서의 과잉추론, 설명 내부의 국소적 모순은 최종 정답률만으로는 드러나지 않는다. 동시에 98.3%의 만점률은 P2-Bench v1.0 의 변별력 한계를 경험적으로 드러냈다. 후속 연구에서는 더 높은 난이도와 미세한 조건 충돌을 포함한 P2-Bench v2 를 구성하고, 독립 평가자 신뢰도와 더 다양한 모델 패밀리를 추가하여 언어별 추론 안정성과 실패 양상을 재검증해야 한다.

11. References

- Anthropic. (2026a). Introducing Claude Opus 5.5. September 22, 2026. <https://www.anthropic.com/claude-opus-5-5>
- Anthropic. (2026b). Introducing Claude Sonnet 5.5. September 28, 2026. <https://www.anthropic.com/claude-sonnet-5-5>
- Anthropic. (2026c). Anthropic’s Transparency Hub: Claude model summaries. <https://www.anthropic.com/transparency>
- Lai, H., & Nissim, M. (2024). mCoT: Multilingual Instruction Tuning for Reasoning Consistency in Language Models. Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 12012–12026. <https://doi.org/10.18653/v1/2024.acl-long.649>
- Plaza, I., Melero, N., del Pozo, C., Conde, J., Reviriego, P., Mayor-Rocher, M., & Grandury, M. (2024). Spanish and LLM Benchmarks: is MMLU Lost in Translation? arXiv:2406.17789. <https://arxiv.org/abs/2406.17789>
- Rein, D., Hou, B. L., Stickland, A. C., Petty, J., Pang, R. Y., Dirani, J., Michael, J., & Bowman, S. R. (2023). GPQA: A Graduate-Level Google-Proof Q&A Benchmark. arXiv:2311.12022. <https://arxiv.org/abs/2311.12022>
- Shi, F., Suzgun, M., Freitag, M., Wang, X., Srivats, S., Vosoughi, S., Chung, H. W., Tay, Y., Ruder, S., Zhou, D., Das, D., & Wei, J. (2023). Language Models Are Multilingual Chain-of-Thought Reasoners. International Conference on Learning Representations (ICLR 2023). <https://arxiv.org/abs/2210.03057>
- Wang, B., Liu, Z., Huang, X., Jiao, F., Ding, Y., Aw, A. T., & Chen, N. F. (2024a). SeaEval for Multilingual Foundation Models: From Cross-Lingual Alignment to Cultural Reasoning. Proceedings of NAACL 2024, 370–390. <https://doi.org/10.18653/v1/2024.naacl-long.22>
- Wang, Y., Ma, X., Zhang, G., Ni, Y., Chandra, A., Guo, S., Ren, W., Arulraj, A., He, X., Jiang, Z., Li, T., Ku, M., Wang, K., Zhuang, A., Fan, R., Yue, X., & Chen, W. (2024b). MMLU-Pro: A More Robust and Challenging Multi-Task Language Understanding Benchmark. arXiv:2406.01574. <https://arxiv.org/abs/2406.01574>
- White, C., Dooley, S., Roberts, M., Pal, A., Feuer, B., Jain, S., Shwartz-Ziv, R., Jain, N., Saifullah, K., Naidu, S., Hegde, C., LeCun, Y., Goldstein, T., Neiswanger, W., & Goldblum, M. (2024). LiveBench: A Challenging, Contamination-Free LLM Benchmark. arXiv:2406.19314. <https://arxiv.org/abs/2406.19314>
- Zhao, R., Liu, Y., Schütze, H., & Hedderich, M. A. (2025). A Comprehensive Evaluation of Multilingual Chain-of-Thought Reasoning: Performance, Consistency, and Faithfulness Across Languages. arXiv:2510.09555. <https://arxiv.org/abs/2510.09555>

12. Appendix

Appendix A. Main Experiment Structure

표 A1. Claude-only 본실험 응답 구성

모델	KR	EN	합계
Claude Opus 5.5	60	60	120
Claude Sonnet 5.5	60	60	120

모델	KR	EN	합계
합계	120	120	240

Appendix B. 실험 메타데이터 및 분석 이력

표 A2. 분석 및 메타데이터 상태

항목	상태	처리
Raw Response	240/240 존재	본 분석에 사용
R2 QC	완료	38 개 Run 재검토, 1개 추가 조정
Exact_Model_Version	240/240 미기록	추정하지 않고 Pending 유지
Execution_Date	240/240 미기록	추정하지 않고 Pending 유지
독립 2 차 평가자	미실시	향후 신뢰도 검증 과제

Appendix C. 출처 및 자료 이력

표 A3. 연구 자료 및 외부 문헌 출처 이력

출처	연도/버전	논문 내 사용 용도	링크/파일
P2-Bench Master Dataset	v1.0	60 문항 정답·해설·Evaluation Target 기준	P2-Bench_Master_Dataset_v1.0.docx / .json
P2-Bench Integrated Experiment Protocol	v1	실험·채점·QC 원칙	P2-Bench_Integrated_Experiment_Protocol_v1.docx
P2-Bench Claude-only Analysis	v2.2	R2 기술통계, paired analysis, ceiling effect	P2-Bench_Claude_Only_Analysis_v2.2.xlsx
Shi et al., MGSM	2023	다국어 추론 선행연구	https://arxiv.org/abs/2210.03057
Lai & Nissim, mCoT	2024	다국어 추론 일관성 선행연구	https://doi.org/10.18653/v1/2024.acl-long.649
Wang et al., SeaEval	2024	다국어 brittleness 및 일관성	https://aclanthology.org/2024.naacl-long.22/
Plaza et al.	2024	번역 기반 벤치마크 타당성 논의	https://arxiv.org/abs/2406.17789
Anthropic Opus 5.5	2026	모델 패밀리 및 공식 모델 설명	https://www.anthropic.com/claude-opus-5-5
Anthropic Sonnet 5.5	2026	모델 패밀리 및 공식 모델 설명	https://www.anthropic.com/claude-sonnet-5-5
Anthropic Transparency Hub	2026	모델 출시·설명 보조 확인	https://www.anthropic.com/transparency
Zhao et al., Multilingual CoT Evaluation	2025	추론 trace 의 성능 · 일 관 성 ·faithfulness 관련 선행연구	https://arxiv.org/abs/2510.09555
Wang et al., MMLU-Pro	2024	벤치마크 포화와 난이도·변별력 강화 논의	https://arxiv.org/abs/2406.01574
White et al., LiveBench	2024	지속 가능한 고난도·오염 저항 평가 설계	https://arxiv.org/abs/2406.19314

출처	연도/버전	논문 내 사용 용도	링크/파일
Rein et al., GPQA	2023	전문가 수준 고난도 벤치마크 설계 사례	https://arxiv.org/abs/2311.12022